

发明名称

一种基于双向深度神经网络的信息系统故障定位方法

摘要

本发明公开了一种基于双向深度神经网络的信息系统故障定位方法，涉及人工智能运维技术领域。该方法旨在解决复杂多源异构数据环境下信息系统故障定位难、响应滞后及可解释性弱的问题。所述方法包括：实时采集系统运行日志与网络流量数据，经特征提取、归一化与融合生成多模态特征向量；将其输入预训练的双向深度神经网络，通过正向推理输出初始故障分布，并结合反向验证分支进行特征重构与偏差校验，协同计算综合置信度评分，筛选生成高置信度故障定位候选集；调用预置领域知识图谱对候选集进行语义关联匹配，基于图计算算法量化各候选节点根因贡献权重，最终生成包含置信度评分及自然语言根因解释的综合故障定位报告。本发明通过多模态数据融合、正反向协同验证与知识图谱约束，有效提升了定位精度与实时性，实现了全流程可解释的智能化运维。

权利要求书

1. 一种基于双向深度神经网络的信息系统故障定位方法，其特征在于，所述方法包括：

第一步，采集信息系统的多源异构数据，所述多源异构数据包括系统运行日志和网络流量数据，对所述多源异构数据进行特征提取与归一化预处理，并通过特征融合将不同模态的特征拼接为统一维度的多模态特征向量；

第二步，将所述多模态特征向量输入预训练的故障定位模型，所述模型基于双向深度神经网络构建，通过正向传播推理与反向溯源验证的协同机制，输出高置信度的故障定位候选集；

第三步，调用预置的领域知识图谱，对所述故障定位候选集中的候选节点进行语义关联匹配，并基于图计算算法量化各候选节点根因贡献权重，生成包含置信度评分及自然语言根因解释的综合故障定位报告。

2. 根据权利要求1所述的方法，其特征在于，所述采集信息系统的多源异构数据，包括：

通过预设的数据采集接口获取信息系统的系统运行日志，所述系统运行日志包括应用日志、系统日志及安全日志；

通过流量探针方式捕获信息系统的网络流量数据，所述网络流量数据包括数据包头部信息及会话连接状态信息；

对所述系统运行日志和网络流量数据添加统一时间戳，并按时间窗口进行对齐与缓存，形成待处理的原始多源数据。

3. 根据权利要求1所述的方法，其特征在于，所述对所述多源异构数据进行特征提取与归一化预处理，并通过特征融合策略将不同模态的特征拼接为统一维度的多模态特征向量，包括：

对所述系统运行日志进行分词与关键事件抽取，采用词嵌入映射生成日志模态特征向量 F_{log} ：

$$F_{log} = \frac{1}{N} \sum_{i=1}^N W_{emb} \cdot one_hot(w_i)$$

其中， w_i 为日志文本中的第*i*个关键词， W_{emb} 为预训练词嵌入矩阵， N 为关键词总数；

对所述网络流量数据解析协议字段并计算统计特征，生成流量模态特征向量 F_{net} ：

$$F_{net} = [\alpha \cdot f_{pkt} + \beta \cdot f_{flow}, \gamma \cdot f_{stat}]$$

其中， f_{pkt} 为数据包头部特征； f_{flow} 为会话流时序特征； f_{stat} 为流量统计特征； α 、 β 、 γ 为预设权重系数且满足 $\alpha + \beta + \gamma = 1$ ；

采用 Z-Score 标准化方法对 F_{log} 和 F_{net} 分别进行归一化处理：

$$F' = \frac{F - \mu}{\sigma}$$

其中， F 为待归一化的原始特征向量； μ 和 σ 分别为对应特征向量在训练集上的均值与标准差； F' 为归一化后的特征向量；

将归一化后的日志模态特征 F'_{log} 与流量模态特征 F'_{net} 按时间戳对齐后，沿特征维度进行拼接，并通过线性投影映射至统一维度 d ，生成所述多模态特征向量 V_{multi} ：

$$V_{multi} = W_{proj} \cdot Concat(F'_{log}, F'_{net}) + b_{proj}$$

其中： $W_{proj} \in \mathbb{R}^{d \times (d_{log} + d_{net})}$ 为投影权重矩阵； b_{proj} 为偏置项； $Concat(\cdot)$ 表示向量拼接操作； d_{log} 和 d_{net} 分别为日志模态与流量模态的特征维度； d 为映射后的统一特征维度。

4. 根据权利要求1所述的方法，其特征在于，所述多模态特征向量输入预训练的故障定位模型，输出高置信度的故障定位候选集，包括：

将所述多模态特征向量输入所述故障定位模型的正向推理分支，进行前向传播计算，输出包含各潜在故障节点初始故障概率的初始故障分布；

将所述初始故障分布输入所述故障定位模型的反向验证分支，基于所述初始故障分布对输入特征进行重构与偏差校验，生成表征各潜在故障节点验证可靠性的反向验证权重；

将所述初始故障分布与所述反向验证权重进行协同融合，提取各潜在故障节点*i*对应的初始故障概率 P_i 与反向验证权重 W_i ，通过逐元素相乘并引入平滑因子 ϵ 的方式，计算得到各潜在故障节点的综合置信度评分 S_{conf} ：

$$S_{conf,i} = P_i \times (W_i + \epsilon)$$

其中， P_i 表示第*i*个潜在故障节点经正向推理分支输出的初始故障概率值，取值范围为[0,1]； W_i 表示第*i*个潜在故障节点经反向验证分支生成的可靠性权重值，用于表征该节点预测结果的可信程度，取值范围为[0,1]； ϵ 为一个极小的正数，作为预设的平滑常数用于防止权重为零导致综合评分失效； S_i 表示第*i*个潜在故障节点融合正向概率与反向验证后的综合置信度评分；

将所述综合置信度评分 S_i 与预设置信阈值 θ 进行比对，筛选出满足 $S_i > \theta$ 条件的潜在故障节点，并按评分由高到低进行排序，生成所述高置信度故障定位候选

集 $D = \{(ID_i, S_i, Type_i, Time_i) \mid S_i > \theta\}$;

每个候选节点记录包含唯一节点标识符 ID_i 、综合置信度评分 S_i 、预测故障类型标签 $Type_i$ 及故障发生时间戳 $Time_i$ 。

5. 根据权利要求 4 所述的方法，其特征在于，所述预训练的故障定位模型，通过以下训练得到：

获取历史信息系统的多源数据及对应的故障根因标签，构建监督训练数据集，并将所述训练数据集中的样本经预处理生成训练用多模态特征向量集 D_{train} ：

$$D_{train} = \{V_{multi}^{(1)}, V_{multi}^{(2)}, \dots, V_{multi}^{(N)}\}$$

其中， $V_{multi}^{(k)}$ 表示第 k 个训练样本的多模态特征向量， N 为训练数据集的样本总数；

将所述训练用多模态特征向量集输入所述双向深度神经网络模型，执行正向推理计算初始故障概率分布，并执行反向验证计算重构特征与反向注意力掩码；

其中，正向推理接收输入 V_{multi} ，输出预测概率分布 P_{fwd} ；

反向验证接收输入 P_{fwd} 和 V_{multi} ，输出重构特征 $\hat{V}$ 和注意力掩码 M_{att} ；

基于所述初始故障概率分布、重构特征及反向注意力掩码，计算联合损失函数 $\mathcal{L}_{total}$ ：

$$\mathcal{L}_{total} = - \sum_{c=1}^C y_c \log(P_{fwd,c}) + \eta_1 \|\hat{V} - V_{multi}\|^2 + \eta_2 \|M_{att}\|_1$$

其中， y_c 为第 c 类故障根因的真实标签值， $P_{fwd,c}$ 为模型正向推理输出的第 c 类故障预测概率， C 为故障类别总数； $\hat{V}$ 为反向验证分支输出的重构特征向量， V_{multi} 为输入的多模态特征向量； M_{att} 为反向验证分支生成的注意力掩码向量； η_1 、 η_2 分别为重构损失权重系数与掩码稀疏正则化系数，且 $\eta_1, \eta_2 \in (0,1)$ ； $\|\cdot\|^2$ 表示欧氏距离平方运算， $\|\cdot\|_1$ 表示 L1 范数； $\mathcal{L}_{total}$ 为联合损失函数值；

基于所述联合损失函数，采用自适应优化算法对模型的可学习参数集合 D_{param} 进行梯度反向传播更新：

$$D_{param}^{(t+1)} = D_{param}^{(t)} - \eta \cdot \nabla_{D_{param}} \mathcal{L}_{total}$$

其中， D_{param} 表示模型所有可学习权重与偏置参数的集合； $D_{param}^{(t)}$ 表示第 t 次迭代时的参数集合值； η 为优化算法的学习率； $\nabla_{D_{param}} \mathcal{L}_{total}$ 表示联合损失函数对

模型参数集合 D_{param} 的梯度向量；

重复迭代执行前向计算、损失评估与参数更新步骤，直至所述联合损失函数收敛至预设阈值或达到预设最大训练轮数，固化模型参数得到所述预训练的故障定位模型。

6. 根据权利要求 1 所述的方法，其特征在于，所述调用预置的领域知识图谱，对所述故障定位候选集中的候选节点进行语义关联匹配，包括：

提取所述高置信度故障定位候选集中各候选节点的故障实体标识、异常状态属性及发生时间戳，构建查询语义特征 Q_{cand} ；

将所述查询语义特征 Q_{cand} 与所述预置的领域知识图谱中的实体节点库及关系拓扑库进行图模式匹配与多跳关联检索，定位与所述候选节点存在逻辑依赖或因果关联的图谱节点集合 $N_{retrieved}$ ；

计算所述候选节点与图谱中历史故障模式节点的匹配置信度 Sim_{score} ：

$$Sim_{score}(Q_{cand}, N_{hist}) = \frac{E(Q_{cand}) \cdot E(N_{hist})}{\|E(Q_{cand})\| \|E(N_{hist})\|}$$

其中， Q_{cand} 为候选节点的查询语义特征向量； N_{hist} 为从图谱节点集合 $N_{retrieved}$ 中选取的任意一个历史故障模式节点； $E(\cdot)$ 表示将图谱节点映射至向量空间的图嵌入函数； $\cdot$ 表示向量点积运算； $\|\cdot\|$ 表示向量的 L2 范数；

根据预设的关联阈值 τ_{sim} 过滤低相关性冗余节点，得到过滤后的节点集合

$N_{filtered}$ ：

$$N_{filtered} = \{n \in N_{retrieved} \mid Sim_{score}(Q_{cand}, n) > \tau_{sim}\}$$

其中， n 表示集合 $N_{retrieved}$ 中的任意节点；

将过滤后的节点按图谱拓扑连通路径进行重组，输出包含语义关联路径及上下文约束的关联候选节点集合 $D_{assoc} = \{(n_i, Path_i, Context_i) \mid n_i \in N_{filtered}\}$ ；

其中， n_i 表示集合中的第 i 个关联节点； $Path_i$ 表示从原始候选节点到 n_i 的图谱拓扑连通路径； $Context_i$ 表示从图谱中提取的与节点 n_i 相关的上下文约束信息。

7. 根据权利要求 6 所述的方法，其特征在于，所述预置的领域知识图谱，通过以下方式得到：

采集信息系统运维领域的多模态知识源数据，所述多模态知识源数据至少包括设备拓扑手册、历史故障工单、系统运行规范及专家经验规则；

采用命名实体识别与关系抽取技术对所述多模态知识源数据进行结构化解析，

构建包含头实体 h 、关系类型 r 及尾实体 t 的初始知识三元组集合 D_{kg} ：

$$D_{kg} = \{(h, r, t)\}$$

将所述初始知识三元组集合 D_{kg} 输入图表示学习模型进行迭代训练，计算图嵌入

损失函数 $\mathcal{L}_{kg}$ ：

$$\mathcal{L}_{kg} = \sum_{(h,r,t) \in D_{kg}} \max(0, \gamma + \|e_h + e_r - e_t\|_2 - \|e_{h'} + e_r - e_{t'}\|_2) + \lambda_{reg} \|D_{kg_param}\|_2^2$$

其中， (h, r, t) 表示来自集合 D_{kg} 的正样本三元组； (h', r, t') 表示通过随机替换头

实体或尾实体生成的负样本三元组； $e_h, e_t, e_{h'}, e_{t'}$ 分别为对应头实体与尾实体的低维稠密向量表征； e_r 为关系类型的向量表征； γ 为边界间隔超参数且 $\gamma > 0$ ； $\|\cdot\|_2$ 表示 L2 范数运算； λ_{reg} 为 L2 正则化系数； D_{kg_param} 为图表示学习模型所有

可学习参数的集合；

当所述图嵌入损失函数收敛或达到预设训练轮数时，提取模型输出的实体向量

表征与关系向量表征，经图数据库持久化存储后构建得到所述预置的领域知识

图谱

8. 根据权利要求 1 所述的方法, 其特征在于, 所述基于图计算算法量化各候选节点的根因贡献权重, 生成包含置信度评分及自然语言根因解释的综合故障定位报告, 包括:

以所述关联候选节点集合中的节点为种子节点, 在所述预置的领域知识图谱中抽取多跳关联实体与关系边, 构建局部故障传播子图;

基于所述局部故障传播子图的拓扑邻接关系与预设转移概率, 执行节点重要性迭代计算, 直至收敛得到各候选节点的图结构贡献分值 W_{graph} :

$$W_{gr} = (1 - \alpha) \cdot v_{seed} + \alpha \cdot T \cdot W_{graph}$$

其中, v_{seed} 为种子节点初始重要性向量 (对应候选集中的节点赋值为 1, 其余图谱节点赋值为 0); T 为基于历史故障频次或专家规则归一化的状态转移矩阵, α 为图计算阻尼因子且 $\alpha \in (0,1)$;

将所述图结构贡献分值与所述双向深度神经网络输出的综合置信度评分进行加权融合, 计算各候选节点的最终根因贡献权重 W_{final} :

$$W_{final} = \mu \cdot S_{conf} + (1 - \mu) \cdot W_{graph}$$

其中, S_{conf} 由权利要求 4 所述的综合置信度评分按候选节点标识符的升序排列构成; μ 为数据驱动置信度与图谱结构重要性的动态融合系数且 $\mu \in (0,1)$;

按所述最终根因贡献权重对候选节点进行降序排列, 将排序首位的节点确定为首要根因节点, 并基于该节点在所述领域知识图谱中的上下文依赖路径与属性元数据, 调用自然语言映射规则或文本生成模型输出根因解释文本;

将所述首要根因节点的最终根因贡献权重、关键关联路径及所述根因解释文本, 按照预设模板进行结构化封装, 生成所述综合故障定位报告。

9. 根据权利要求 8 所述的方法, 其特征在于, 所述综合故障定位报告, 包括: 首要根因节点标识字段, 用于唯一标识经权重排序确定的首要故障根因实体;

根因置信度量化学段, 包含所述首要根因节点的最终根因贡献权重评分 W_{final}

及对应的置信等级分类标签 L_{conf} ; 其中, 所述最终根因贡献权重评分 W_{final} 为根据权利要求 8 所述的计算步骤, 将双向深度神经网络输出的数据驱动综合置信度评分 S_{conf} 与知识图谱计算得到的图结构贡献分值 S_{graph} 进行加权融合后, 经降序排列取首位节点所确定的数值, 其计算公式为:

$$W_{final} = \alpha \cdot S_{conf} + (1 - \alpha) \cdot S_{grap} ,$$

其中, α 为数据驱动置信度与图谱结构重要性的动态融合系数, 且 $0 < \alpha < 1$;

所述置信等级分类标签 L_{conf} 则是通过将所述最终根因贡献权重评分 W_{final} 与预设的多个数值区间进行比对映射生成, 各数值区间分别对应极高置信、高置信、中置信及低置信四个等级类别;

图谱关联路径字段, 记录所述首要根因节点在所述预置的领域知识图谱中与所述故障定位候选集内其他节点之间的多跳依赖关系链及因果推理路径;

自然语言根因解释字段，存储基于所述图谱关联路径与节点属性元数据，调用预置的自然语言模板库输出的根因成因描述及处置建议文本，所述自然语言模板库包含故障类型、根因位置、影响范围及推荐处置策略的标准化描述模板；

技术领域：

[1] 本发明涉及人工智能运维技术领域，具体而言，是一种基于双向深度神经网络的信息系统故障定位方法，该方法适用于复杂多源异构数据环境下信息系统日志与网络流量的实时采集、特征融合及智能根因分析场景，可实现故障定位的高效性、实时性及全流程可解释的智能化运维效果，属于计算机信息技术、双向深度神经网络、知识图谱与运维工程深度融合的交叉技术领域。

背景技术：

[2] 在信息系统智能化运维与故障管理过程中，快速、精准的故障根因定位是保障业务连续性与服务稳定性的关键因素。随着信息系统架构向分布式、微服务化方向演进，系统运行过程中产生的日志数据、网络流量数据及拓扑状态数据呈现多源异构、高维稀疏与时空耦合的特征，传统基于规则匹配或单模态分析的故障定位方法难以有效挖掘多源数据间的深层关联，导致故障响应滞后、定位精度不足及决策过程缺乏可解释性。

[3] 现有信息系统故障定位技术主要存在以下局限性：一方面，多数方法仅依赖单一数据源，未能充分融合日志语义、流量时序与拓扑依赖等多模态特征，导致在复杂故障场景下特征表征能力不足、误报漏报率高；另一方面，现有 AI 模型多采用单向黑盒推理机制，缺乏对故障传播路径的反向验证与知识约束，难以输出具备因果逻辑与人类可读的根因解释，制约了运维人员的高效决策与快速处置。因此，有必要设计一种基于双向深度神经网络的信息系统故障定位方法，以解决上述技术问题。

发明内容：

[4] 针对上述技术的不足，本发明的目的在于解决杂多源异构数据环境下信息系统故障定位难、响应滞后及可解释性弱的问题。

[5] 为实现上述目的，本发明采取的技术方案如下：

[6] 所述一种基于双向深度神经网络的信息系统故障定位方法包括以下步骤：

[7] 第一步，采集信息系统的多源异构数据，所述多源异构数据包括系统运行日志和网络流量数据，对所述多源异构数据进行特征提取与归一化预处理，并通过特征融合将不同模态的特征拼接为统一维度的多模态特征向量；

[8] 第二步，将所述多模态特征向量输入预训练的故障定位模型，所述模型基于双向深度神经网络构建，通过正向传播推理与反向溯源验证的协同机制，输出高置信度的故障定位候选集；

[9] 第三步，调用预置的领域知识图谱，对所述故障定位候选集中的候选节点进行语义关联匹配，并基于图计算算法量化各候选节点的根因贡献权重，生成包含置信度评分及自然语言根因解释的综合故障定位报告。

[10] 优选地，所述采集信息系统的多源异构数据，包括：

[11] 通过预设的数据采集接口获取信息系统的系统运行日志，所述系统运行日

志包括应用日志、系统日志及安全日志；

[12] 通过流量探针方式捕获信息系统的网络流量数据，所述网络流量数据包括数据包头部信息及会话连接状态信息；

[13] 对所述系统运行日志和网络流量数据添加统一时间戳，并按时间窗口进行对齐与缓存，形成待处理的原始多源数据。

[14] 进一步地，所述对所述多源异构数据进行特征提取与归一化预处理，并通过特征融合策略将不同模态的特征拼接为统一维度的多模态特征向量，包括：

[15] 对所述系统运行日志进行分词与关键事件抽取，采用词嵌入映射生成日志模态特征向量 F_{log} ：

$$[16] F_{log} = \frac{1}{N} \sum_{i=1}^N W_{emb} \cdot one_hot(w_i)$$

[17] 其中， w_i 为日志文本中的第 i 个关键词， W_{emb} 为预训练词嵌入矩阵， N 为关键词总数；

[18] 对所述网络流量数据解析协议字段并计算统计特征，生成流量模态特征向量 F_{net} ：

$$[19] F_{net} = [\alpha \cdot f_{pkt} + \beta \cdot f_{flow}, \gamma \cdot f_{stat}]$$

[20] 其中， f_{pkt} 为数据包头部特征； f_{flow} 为会话流时序特征； f_{stat} 为流量统计特征； α 、 β 、 γ 为预设权重系数且满足 $\alpha + \beta + \gamma = 1$ ；

[21] 采用 Z-Score 标准化方法对 F_{log} 和 F_{net} 分别进行归一化处理：

$$[22] F' = \frac{F - \mu}{\sigma}$$

[23] 其中， F 为待归一化的原始特征向量； μ 和 σ 分别为对应特征向量在训练集上的均值与标准差； F' 为归一化后的特征向量；

[24] 将归一化后的日志模态特征 F'_{log} 与流量模态特征 F'_{net} 按时间戳对齐后，沿特征维度进行拼接，并通过线性投影映射至统一维度 d ，生成所述多模态特征向量 V_{multi} ：

$$[25] V_{multi} = W_{proj} \cdot Concat(F'_{log}, F'_{net}) + b_{proj}$$

[26] 其中： $W_{proj} \in \mathbb{R}^{d \times (d_{log} + d_{net})}$ 为投影权重矩阵； b_{proj} 为偏置项； $Concat(\cdot)$

表示向量拼接操作； d_{log} 和 d_{net} 分别为日志模态与流量模态的特征维度； d 为映射后的统一特征维度。

[27] 优选地，所述多模态特征向量输入预训练的故障定位模型，输出高置信度的故障定位候选集，包括：

[28] 将所述多模态特征向量输入所述故障定位模型的正向推理分支，进行前向传播计算，输出包含各潜在故障节点初始故障概率的初始故障分布；

[29] 将所述初始故障分布输入所述故障定位模型的反向验证分支，基于所述初始故障分布对输入特征进行重构与偏差校验，生成表征各潜在故障节点验证可

靠性的反向验证权重；

[30] 将所述初始故障分布与所述反向验证权重进行协同融合，计算得到各潜在故障节点的综合置信度评分；

[31] 将所述综合置信度评分与预设置信阈值进行比对，筛选出综合置信度评分大于所述预设置信阈值的潜在故障节点，并按评分由高到低进行排序，生成所述高置信度故障定位候选集。

[32] 其中，所述高置信度故障定位候选集为结构化数据序列，每个候选节点记录包含唯一节点标识符与综合置信度评分。

进一步地，所述对所述多源异构数据进行特征提取与归一化预处理，并通过特征融合策略将不同模态的特征拼接为统一维度的多模态特征向量，包括：

[33] 对所述系统运行日志进行分词与关键事件抽取，采用词嵌入映射生成日志模态特征向量 F_{log} ：

$$[34] F_{log} = \frac{1}{N} \sum_{i=1}^N W_{emb} \cdot one_{hot}(w_i)$$

[35] 其中， w_i 为日志文本中的第 i 个关键词， W_{emb} 为预训练词嵌入矩阵， N 为关键词总数；对所述网络流量数据解析协议字段并计算统计特征，生成流量模态特征向量 F_{net} ：

$$[36] F_{net} = [\alpha \cdot f_{pkt} + \beta \cdot f_{flow}, \gamma \cdot f_{stat}]$$

[37] 其中， f_{pkt} 为数据包头部特征； f_{flow} 为会话流时序特征； f_{stat} 为流量统计特征； α 、 β 、 γ 为预设权重系数且满足 $\alpha + \beta + \gamma = 1$ ；

[38] 采用 Z-Score 标准化方法对 F_{log} 和 F_{net} 分别进行归一化处理：

$$[39] F' = \frac{F - \mu}{\sigma}$$

[40] 其中， F 为待归一化的原始特征向量； μ 和 σ 分别为对应特征向量在训练集上的均值与标准差； F' 为归一化后的特征向量；

[41] 将归一化后的日志模态特征 F'_{log} 与流量模态特征 F'_{net} 按时间戳对齐后，沿特征维度进行拼接，并通过线性投影映射至统一维度 d ，生成所述多模态特征向量 V_{multi} ：

$$[42] V_{multi} = W_{proj} \cdot Concat(F'_{log}, F'_{net}) + b_{proj}$$

[43] 其中： $W_{proj} \in \mathbb{R}^{d \times (d_{log} + d_{net})}$ 为投影权重矩阵； b_{proj} 为偏置项； $Concat(\cdot)$

表示向量拼接操作； d_{log} 和 d_{net} 分别为日志模态与流量模态的特征维度； d 为映射后的统一特征维度。

[44] 优选地，所述多模态特征向量输入预训练的故障定位模型，输出高置信度的故障定位候选集，包括：

[45] 将所述多模态特征向量输入所述故障定位模型的正向推理分支，进行前向传播计算，输出包含各潜在故障节点初始故障概率的初始故障分布；

[46] 将所述初始故障分布输入所述故障定位模型的反向验证分支，基于所述初始故障分布对输入特征进行重构与偏差校验，生成表征各潜在故障节点验证可靠性的反向验证权重；

[47] 将所述初始故障分布与所述反向验证权重进行协同融合，提取各潜在故障节点*i*对应的初始故障概率 P_i 与反向验证权重 W_i ，通过逐元素相乘并引入平滑因子 ϵ 的方式，计算得到各潜在故障节点的综合置信度评分 S_{conf} ：

$$[48] S_{conf,i} = P_i \times (W_i + \epsilon)$$

[49] 其中， P_i 表示第*i*个潜在故障节点经正向推理分支输出的初始故障概率值，取值范围为[0,1]； W_i 表示第*i*个潜在故障节点经反向验证分支生成的可靠性权重值，用于表征该节点预测结果的可信程度，取值范围为[0,1]； ϵ 为一个极小的正数，作为预设的平滑常数用于防止权重为零导致综合评分失效； S_i 表示第*i*个潜在故障节点融合正向概率与反向验证后的综合置信度评分；

[50] 将所述综合置信度评分 S_i 与预设置信阈值 θ 进行比对，筛选出满足 $S_i > \theta$ 条件的潜在故障节点，并按评分由高到低进行排序，生成所述高置信度故障定位候选集 $D = \{(ID_i, S_i, Type_i, Time_i) \mid S_i > \theta\}$ ；

[51] 每个候选节点记录包含唯一节点标识符 ID_i 、综合置信度评分 S_i 、预测故障类型标签 $Type_i$ 及故障发生时间戳 $Time_i$ 。

[52] 进一步地，所述预训练的故障定位模型，通过以下训练得到：

[53] 获取历史信息系统的多源数据及对应的故障根因标签，构建监督训练数据集，并将所述训练数据集中的样本经预处理生成训练用多模态特征向量集

D_{train} ：

$$[54] D_{train} = \{V_{multi}^{(1)}, V_{multi}^{(2)}, \dots, V_{multi}^{(N)}\}$$

[55] 其中， $V_{multi}^{(k)}$ 表示第*k*个训练样本的多模态特征向量， N 为训练数据集的样本总数；

[56] 将所述训练用多模态特征向量集输入所述双向深度神经网络模型，执行正向推理计算初始故障概率分布，并执行反向验证计算重构特征与反向注意力掩码；

其中，正向推理接收输入 V_{multi} ，输出预测概率分布 P_{fwd} ；

反向验证接收输入 P_{fwd} 和 V_{multi} ，输出重构特征 $\hat{V}$ 和注意力掩码 M_{att} ；

[57] 基于所述初始故障概率分布、重构特征及反向注意力掩码，计算联合损失函数 $\mathcal{L}_{total}$ ：

$$[58] \mathcal{L}_{total} = -\sum_{c=1}^C y_c \log(P_{fwd,c}) + \eta_1 \|\hat{V} - V_{multi}\|^2 + \eta_2 \|M_{att}\|_1$$

其中， y_c 为第*c*类故障根因的真实标签值， $P_{fwd,c}$ 为模型正向推理输出的第*c*类故障预测概率， C 为故障类别总数； $\hat{V}$ 为反向验证分支输出的重构特征向量， V_{multi} 为输入的多模态特征向量； M_{att} 为反向验证分支生成的注意力掩码向量； η_1 、 η_2 分别为重构损失权重系数与掩码稀疏正则化系数，且 $\eta_1, \eta_2 \in (0,1)$ ； $\|\cdot\|^2$

表示欧氏距离平方运算, $\|\cdot\|_1$ 表示 L1 范数; $\mathcal{L}_{total}$ 为联合损失函数值;

[59] 基于所述联合损失函数, 采用自适应优化算法对模型的可学习参数集合 D_{param} 进行梯度反向传播更新:

$$[60] D_{param}^{(t+1)} = D_{param}^{(t)} - \eta \cdot \nabla_{D_{param}} \mathcal{L}_{total}$$

其中, D_{param} 表示模型所有可学习权重与偏置参数的集合; $D_{param}^{(t)}$ 表示第 t 次迭代时的参数集合值; η 为优化算法的学习率; $\nabla_{D_{param}} \mathcal{L}_{total}$ 表示联合损失函数对

模型参数集合 D_{param} 的梯度向量;

[61] 重复迭代执行前向计算、损失评估与参数更新步骤, 直至所述联合损失函数收敛至预设阈值或达到预设最大训练轮数, 固化模型参数得到所述预训练的故障定位模型。

[62] 优选地, 所述调用预置的领域知识图谱, 对所述故障定位候选集中的候选节点进行语义关联匹配, 包括:

[63] 提取所述高置信度故障定位候选集中各候选节点的故障实体标识、异常状态属性及发生时间戳, 构建查询语义特征 Q_{cand} ;

[64] 将所述查询语义特征 Q_{cand} 与所述预置的领域知识图谱中的实体节点库及关系拓扑库进行图模式匹配与多跳关联检索, 定位与所述候选节点存在逻辑依赖或因果关联的图谱节点集合 $N_{retrieved}$;

[65] 计算所述候选节点与图谱中历史故障模式节点的匹配置信度 Sim_{score} :

$$[66] Sim_{score}(Q_{cand}, N_{hist}) = \frac{E(Q_{cand}) \cdot E(N_{hist})}{\|E(Q_{cand})\| \|E(N_{hist})\|}$$

[67] 其中, Q_{cand} 为候选节点的查询语义特征向量; N_{hist} 为从图谱节点集合 $N_{retrieved}$ 中选取的任意一个历史故障模式节点; $E(\cdot)$ 表示将图谱节点映射至向量空间的图嵌入函数; $\cdot$ 表示向量点积运算; $\|\cdot\|$ 表示向量的 L2 范数;

[68] 根据预设的关联阈值 τ_{sim} 过滤低相关性冗余节点, 得到过滤后的节点集合 $N_{filtered}$:

$$[69] N_{filtered} = \{n \in N_{retrieved} \mid Sim_{score}(Q_{cand}, n) > \tau_{sim}\}$$

[70] 其中, n 表示集合 $N_{retrieved}$ 中的任意节点;

[71] 将过滤后的节点按图谱拓扑连通路径进行重组, 输出包含语义关联路径及上下文约束的关联候选节点集合

$$[72] D_{assoc} = \{(n_i, Path_i, Context_i) \mid n_i \in N_{filtered}\};$$

[73] 其中, n_i 表示集合中的第 i 个关联节点; $Path_i$ 表示从原始候选节点到 n_i 的图谱拓扑连通路径; $Context_i$ 表示从图谱中提取的与节点 n_i 相关的上下文约束信息。

[74] 进一步地, 所述预置的领域知识图谱, 通过以下方式得到:

[75] 采集信息系统运维领域的多模态知识源数据, 所述多模态知识源数据至少包括设备拓扑手册、历史故障工单、系统运行规范及专家经验规则;

[76] 采用命名实体识别与关系抽取技术对所述多模态知识源数据进行结构化解析，构建包含头实体 h 、关系类型 r 及尾实体 t 的初始知识三元组集合 D_{kg} ：

$$[77] D_{kg} = \{(h, r, t)\}$$

[78] 将所述初始知识三元组集合 D_{kg} 输入图表示学习模型进行迭代训练，计算图嵌入损失函数 $\mathcal{L}_{kg}$ ：

$$[79] \mathcal{L}_{kg} = \sum_{(h,r,t) \in D_{kg}} \max(0, \gamma + \|e_h + e_r - e_t\|_2 - \|e_{h'} + e_r - e_{t'}\|_2) +$$

$$\lambda_{reg} \|D_{kg_param}\|_2^2$$

[80] 其中， (h, r, t) 表示来自集合 D_{kg} 的正样本三元组； (h', r, t') 表示通过随机替换头实体或尾实体生成的负样本三元组； $e_h, e_t, e_{h'}, e_{t'}$ 分别为对应头实体与尾实体的低维稠密向量表征； e_r 为关系类型的向量表征； γ 为边界间隔超参数且 $\gamma > 0$ ； $\|\cdot\|_2$ 表示L2范数运算； λ_{reg} 为L2正则化系数； D_{kg_param} 为图表示学习模型所有可学习参数的集合；

[81] 当所述图嵌入损失函数收敛或达到预设训练轮数时，提取模型输出的实体向量表征与关系向量表征，经图数据库持久化存储后构建得到所述预置的领域知识图谱

[82] 优选地，所述基于图计算算法量化各候选节点的根本贡献权重，生成包含置信度评分及自然语言根本解释的综合故障定位报告，包括：

[83] 以所述关联候选节点集合中的节点为种子节点，在所述预置的领域知识图谱中抽取多跳关联实体与关系边，构建局部故障传播子图；

[84] 基于所述局部故障传播子图的拓扑邻接关系与预设转移概率，执行节点重要性迭代计算，直至收敛得到各候选节点的图结构贡献分值 W_{graph} ：

$$[85] W_{graph} = (1 - \alpha) \cdot v_{seed} + \alpha \cdot T \cdot W_{graph}$$

[86] 其中， v_{seed} 为种子节点初始重要性向量（对应候选集中的节点赋值为1，其余图谱节点赋值为0）； T 为基于历史故障频次或专家规则归一化的状态转移矩阵， α 为图计算阻尼因子且 $\alpha \in (0,1)$ ；

[87] 将所述图结构贡献分值与所述双向深度神经网络输出的综合置信度评分进行加权融合，计算各候选节点的最终根本贡献权重 W_{final} ：

$$[88] W_{final} = \mu \cdot S_{conf} + (1 - \mu) \cdot W_{graph}$$

[89] 其中， S_{conf} 由权利要求4所述的综合置信度评分按候选节点标识符的升序排列构成； μ 为数据驱动置信度与图谱结构重要性的动态融合系数且 $\mu \in (0,1)$ ；

[90] 按所述最终根本贡献权重对候选节点进行降序排列，将排序首位的节点确

定为首要根因节点，并基于该节点在所述领域知识图谱中的上下文依赖路径与属性元数据，调用自然语言映射规则或文本生成模型输出根因解释文本；

[91] 将所述首要根因节点的最终根因贡献权重、关键关联路径及所述根因解释文本，按照预设模板进行结构化封装，生成所述综合故障定位报告。

[92] 进一步地，所述综合故障定位报告，包括：

[93] 首要根因节点标识字段，用于唯一标识经权重排序确定的首要故障根因实体；

[94] 根因置信度量化字段，包含所述首要根因节点的最终根因贡献权重评分

W_{final} 及对应的置信等级分类标签 L_{conf} ；其中，所述最终根因贡献权重评分

W_{final} 为根据权利要求 8 所述的计算步骤，将双向深度神经网络输出的数据驱

动综合置信度评分 S_{conf} 与知识图谱计算得到的图结构贡献分值 S_{graph} 进行加权

融合后，经降序排列取首位节点所确定的数值，其计算公式为：

[95] $W_{final} = \alpha \cdot S_{conf} + (1 - \alpha) \cdot S_{graph}$ ，

[96] 其中， α 为数据驱动置信度与图谱结构重要性的动态融合系数，且 $0 < \alpha <$

1；所述置信等级分类标签 L_{conf} 则是通过将所述最终根因贡献权重评分 W_{final} 与

预设的多个数值区间进行比对映射生成，各数值区间分别对应极高置信、高置信、中置信及低置信四个等级类别；

[97] 图谱关联路径字段，记录所述首要根因节点在所述预置的领域知识图谱中与所述故障定位候选集内其他节点之间的多跳依赖关系链及因果推理路径；

[98] 自然语言根因解释字段，存储基于所述图谱关联路径与节点属性元数据，调用预置的自然语言模板库输出的根因成因描述及处置建议文本，所述自然语言模板库包含故障类型、根因位置、影响范围及推荐处置策略的标准化描述模板；

附图说明：

[99] 图 1 为本发明基于双向深度神经网络的信息系统故障定位方法整体流程示意图

[100] 图 2 为故障定位模型结构示意图




图 1




图 2