

《基于 AI 生成代码错误修复的规则引擎工具》

1. 背景与目标

1.1 背景

- 行业痛点：**当前 LLM 在代码生成领域应用广泛，但语法错误、逻辑偏差、测试不兼容等问题频发。传统修复工具依赖事后校验，存在延迟高、适配性差的痛点，难以满足开发场景的实时性需求。
- 技术契机：**大语言模型中间表示应用、轻量级探针模型（线性/LoRA）、行级错误标注技术逐步成熟，为从“函数级事后修复”向“行级实时干预”演进提供可能。
- 项目初衷：**复用 token 级探针框架，构建高质量代码错误数据集，训练轻量探针实现错误行精准定位，结合修复模板库与实时干预机制，达成代码实时检测修复，平衡代码生成的实用性与准确性。

1.2 产品目标

- 核心定位：**面向代码生成场景的轻量级、低延迟行级错误检测与实时修复规则引擎工具。
- 业务目标：**突破现有 MBPP 数据集仅支持函数级正确性判定的局限，实现局部逻辑层面行级错误精准识别；验证探针模型在代码生成后阶段的实时检测能力。
- 交付目标：**产出标准化 JSONL 行级标注数据集、线性/LoRA 探针模型权重、可复现训练/推理脚本、规则引擎原型及技术报告/论文，为 AI 辅助编程规模化落地提供关键支撑。

2. 故事介绍

2.1 用户场景

用户类型	核心场景	交互行为
AI 辅助开发者/程序员	IDE 编码、代码生成 API 调用、CI/CD 流水线	触发 AI 代码生成 → 实时查看行级错误高亮与原因解释 → 一键应用规则引擎修复建议 → 验证测试用例通过

算法研究员/高校学生	模型中间状态分析、错误检测实验、论文复现	调用标准化 JSONL 数据集 → 运行探针训练/推理脚本 → 对比基线与 LoRA 探针性能 → 导出行级评估指标
工程团队/企业研发	代码生成服务集成、低延迟检测模块部署	接入探针检测接口 → 配置修复模板库 → 监控推理延迟与修复成功率 → 迭代业务逻辑错误规则

2.2 价值分析

- 技术价值：**创新融合 LLM 精细化分析能力与探针模型快速检测优势，突破单一技术路径局限；揭示代码错误特征的跨模型泛化规律，拓展 token 级检测框架应用边界。
- 应用价值：**实现代码错误实时识别与干预，降低调试成本、提升开发效率，适配 IDE 与代码生成 API 等实时开发场景。
- 学术与生态价值：**填补行级错误标注数据集细分空白，提供标准化 JSONL 数据与可复现脚本，推动代码生成领域可靠性技术迭代。

2.3 核心体验路径

Plain Text

[数据输入] MBPP 原任务/多源生成代码 → 本地运行测试用例 → 函数级正确性判定

↓

[行级标注] 拼接任务描述/用例/代码/运行结果 → 输入专业 LLM 逐行分析 → 输出行级标签/类型/原因 → 人工复核 → 标准化 JSONL 数据集

↓

[探针训练] 提取代码生成模型中间隐藏状态 → 训练线性/LoRA 探针 → 调整损失函数/正则化参数 → 保存训练/推理脚本

↓

[实时检测] 代码流式生成 → 探针实时读取隐藏特征 → 行级错误定位与置信度输出

↓

[规则修复] 触发修复模板库匹配 → 实时干预/代码替换 → 输出修复后代码 → 测试用例二次验证

↓

[评估迭代] 行级专项指标计算 → 低延迟验证 → 跨模型泛化实验 → 参数调优/成

2.4 产品指标预测

指标维度	目标/预期达成值	评估依据
数据集质量	标准化 JSONL 格式，覆盖函数级判定+行级定位/类型/原因，人工复核保障精度	标注脚本统计、复核一致率记录
检测精度	突破函数级局限，实现局部逻辑错误行级精准定位（具体数值以实验实测为准）	行级 Precision/Recall/F1 专项指标
响应延迟	低延迟实时检测，适配 IDE 与代码生成 API 流式场景	推理耗时监控（ms 级）、P99 延迟测试
泛化能力	揭示代码错误特征跨模型泛化规律，验证多源生成代码适配性	跨模型对比实验、泛化得分评估
交付完整性	可复现脚本集、规则引擎原型、技术报告/论文、预算执行合规	结题评审、成果汇编、经费决算表

2.5 路径规划

阶段	周期	核心任务	交付物
Phase 1 立项与准备	2026 年 3 月	方向论证、目标分工、环境搭建、实施方案编制	项目规划文档、开发环境配置清单
Phase 2 调研与设计	2026 年 4-5 月	文献检索、技术方案拟定、模块划	技术方案书、数据集预处理结果、模

		分、标注规范/评估指标确定、数据收集预处理	块设计说明
Phase 3 开发与训练	2026 年 6-10 月	标注/训练/推理脚本编写调试、线性/LoRA 探针训练优化、多轮实验测试、低延迟验证	JSONL 数据集、探针模型权重、实验日志、优化脚本
Phase 4 评估与固化	2026 年 11-12 月	行级指标评估、跨模型泛化实验、规则引擎联调、成果汇编、论文撰写、结题答辩	评估报表、规则引擎原型、技术报告/论文、结题材料

3. 概要设计

3.1 模块设计

- 数据构建模块：**负责 MBPP 任务数据收集、本地测试用例运行、LLM 辅助行级标注、人工复核校验，输出标准化 JSONL 数据集。
- 探针检测模块：**负责提取代码生成模型中间隐藏状态，加载线性/LoRA 探针分类头，实现行级逻辑错误实时判别。
- 规则修复模块：**内置修复模板库，接收探针错误信号后触发实时干预机制，完成错误行替换或修复建议生成。
- 评估验证模块：**提供行级专项评估指标计算、低延迟监控、跨模型泛化实验支持，管理可复现脚本与实验日志。

3.2 功能清单

模块	功能/内容项	说明（严格依据原文）
数据构建	运行测试判定	本地执行测试用例，判定代码整体功能是否满足任务要求（函数级）

	LLM 行级标注	以代码行为最小单元，标注正确/错误、错误类型、自然语言原因说明
	人工复核校验	修正自动标注偏差，保障 JSONL 数据集质量与精度
探针检测	中间状态读取	实时获取代码生成模型隐藏层特征，作为探针输入
	线性/LoRA 探针	轻量级错误检测模型，以行级错误标签为监督信号完成判别
	参数自适应优化	针对性调整损失函数与正则化参数，兼顾轻量级与检测性能
规则修复	修复模板库	针对常见错误类型预设规则/模板，支持快速匹配
	实时干预引擎	检测触发后即时注入修复代码或提示，达成检测修复闭环
评估验证	行级指标计算	设计适用于行级错误检测的专项评估指标，系统对比基线与探针性能
	延迟与泛化监控	验证低延迟检测能力，开展跨模型泛化实验，记录实验数据

3.3 页面结构（开发者工具/实验控制台架构）

Plain Text

[开发者 IDE/控制台界面]

└─ 代码生成/编辑区：实时流式显示 AI 生成代码，支持任务描述与测试用例输

入

- └ 探针检测状态栏：显示中间表示提取进度、行级错误高亮标记、检测置信度
- └ 错误详情面板：错误行号、错误类型、LLM 生成原因解释、修复建议入口
- └ 规则修复操作区：模板匹配结果展示、一键应用修复/手动调整、二次测试验证

证

- └ 实验/评估看板（研究端）：数据集统计、探针训练曲线、行级指标报表、延迟日志、脚本管理

4. 详细设计

4.1 数据标注逻辑

- **突破点**：现有 MBPP 数据集仅覆盖函数级正确性判定，缺乏行级定位、类型及原因标注。
- **流程**：生成代码 → 本地运行测试 → 函数级打标 → 拼接上下文（任务描述/用例/代码/运行结果） → 输入专业 LLM 逐行分析 → 输出 JSONL（行号, 标签, 类型, 原因） → 人工复核修正偏差。
- **输出规范**：标准化 JSONL 格式，确保满足模型训练需求与后续扩展。

4.2 探针模型架构

- **输入**：代码生成模型的中间隐藏状态（Intermediate Representations）。
- **监督信号**：行级错误标签（正确行/错误行）。
- **模型选型**：线性探针（基线对比）与 LoRA 探针（主力优化）。
- **训练策略**：结合数据集特性，针对性调整损失函数与正则化参数；保存完整训练与推理脚本，支持实验复现与后续扩展。

4.3 规则引擎与实时干预

- **机制**：结合修复模板库与实时干预机制。当探针判定某行存在逻辑错误时，触发规则引擎匹配对应修复模板，在代码生成后阶段实现低延迟干预。
- **目标**：达成“实时检测-精准定位-快速修复”闭环，提升代码生成实用性与准确性。

4.4 边界与约束

- **语言与场景**：聚焦 Python 代码（MBPP 类函数生成任务），侧重局部逻辑错误而非纯语法错误。
- **技术依赖**：依赖生成模型开放中间表示接口；低延迟要求限制模型参数量，需权衡精度与速度。
- **泛化验证**：跨模型泛化规律需通过多源生成代码实验验证，复杂业务逻辑错误识别为后续攻坚方向。

5. 交付设计

5.1 数据分析设计

埋点设计（系统日志与实验追踪触点）

触点类型	采集字段/行为	对应原文方法
数据流水线埋点	测试用例通过率、函数级判定结果、LLM 标注耗时、人工复核修正率	本地运行测试、JSONL 构建流程监控、自动标注偏差修正
模型训练埋点	损失函数曲线、正则化参数值、验证集行级准确率、LoRA 秩/学习率配置	训练脚本日志、参数调优记录、复现脚本管理
实时推理埋点	单行检测耗时(ms)、中间表示提取延迟、错误触发频次、模板匹配成功率	低延迟验证实验、规则引擎干预日志、IDE/API 适配测试
评估实验埋点	行级 Precision/Recall/F1、跨模型泛化得分、基线 vs 探针对比数据	专项评估指标计算、多模型实验记录、性能系统对比

报表设计

报表名称	核心指标/维度	数据源与输出形式
数据集质量报表	JSONL 样本量、行级标注分布、人工复核一致率、错误类型占比	标注脚本统计、复核记录表、数据集说明文档
探针性能看板	行级检测精度、训练收敛曲线、参数量/计算开销、基线对比结果	PyTorch/训练框架日志、实验对比表、模型权重清单
实时性验证报表	平均/P99 推理延迟、流式	延迟监控脚本、场景测试

	干预成功率、IDE/API 适配测试结果	记录、低延迟验证报告
泛化与修复报表	跨模型错误特征泛化得分、规则模板覆盖率、修复后测试用例通过率	多模型实验数据、修复引擎日志、规则库版本记录
结题综合报告	技术路线验证结论、可复现脚本清单、论文/技术文档、预算执行明细（8000元）	项目总结、成果汇编、经费决算表、结题评审材料